جزوه‌ی هفته‌ی مکمل: وایب‌کدینگ در مهندسی

هوش مصنوعی کد می‌نویسد، مهندس آن را راستی‌آزمایی می‌کند: بررسی، آزمون، بازبینی و محدودیت‌ها

هوش مصنوعی برای مهندسی هوافضا و مکانیک (دکتری)، هفته‌ی مکمل

منشأ محتوا: محتوای جدید (هفته‌ی مکمل). تعریف‌ها، تصویر «سرآشپز»، داستان‌های هشداردهنده و قاعده‌های واگذاری با بازنویسی از G. Kim و S. Yegge, *Vibe Coding* (IT Revolution, 2025), Chs. 1, 4 and 7 آمده‌اند. واژه‌ی Karpathy و قاعده‌ی بازبینی از S. Willison, “Not all AI-assisted programming is vibe coding” (19 Mar 2025) است. نگاه ایمنی با N. AlNasser, *The Vibe Coder’s Handbook* (2026), Chs. 14 and 17 مقایسه شد و آمارهای بی‌منبع آن به کار نرفته است. راستی‌آزمایی کد از Veluri، Roy و Luke, *Computers & Fluids* (2012) و آزمون جهش از Lipton، DeMillo و Sayward, *IEEE Computer* 11(4) (1978) است. نتایج مطالعات در فهرست منابع آمده و هر یک در 2026-10-16 در متن اصلی خوانده شده است. بقیه‌ی عددها در محیط درس (دفترچه‌ی آزمایشگاه) محاسبه شده‌اند.

۱. مسئله

پهپاد ماژول M3 ارتفاع فشاری را از فشارسنج لازم دارد. یک درخواست به دستیار هوش مصنوعی («تابع `pressure_altitude(p)` را برای ISA بنویس») می‌تواند پاسخ‌هایی مانند چهار کاندیدای آزمایشگاه بدهد که به‌عنوان مثال آموزشی نوشته شده‌اند. هر چهار اجرا می‌شوند، docstring دارند و عدد برمی‌گردانند. در 50 kPa می‌دهند: 5574.4 m، 888.8 -159 m، 172.2 m و 5574.4 m. با کدام پرواز می‌کنید؟

Andrej Karpathy در فوریه‌ی ۲۰۲۵ «وایب‌کدینگ» را برای تسلیم‌شدن به حس و فراموش‌کردن این‌که «کد اصلاً وجود دارد» به کار برد و آن را برای «پروژه‌های دورریختنی آخر هفته» قابل‌قبول دانست. Simon Willison مرزی را کشید که برای مهندس مهم است: اگر کد را بازبینی و آزمون کنید و بتوانید توضیحش دهید، دیگر وایب‌کدینگ نمی‌کنید. Kim و Yegge واژه را گسترده‌تر به کار می‌برند ولی همان قاعده را در تصویر «سرآشپز» نگه می‌دارند: آشپزی را می‌توان واگذار کرد، مسئولیت آنچه از آشپزخانه بیرون می‌رود را نه. این هفته درباره‌ی همین حالت دوم است.

۲. چرا کد باورپذیر خطرناک است

کد نوشته‌شده با هوش مصنوعی به‌ندرت با خطای اجرا شکست می‌خورد. مثل کد انسانی شکست می‌خورد، فقط سریع‌تر و با توضیحاتی مطمئن: ثابت غلط، رابط یکای مستندنشده، محدودکننده‌ی «ایمنی» که فیزیک را عوض می‌کند، یا اشتباه تایپی که مرتبه‌ی دقت روش را پایین می‌آورد. Kim و Yegge (فصل ۴) از عاملی می‌گویند که بی‌صدا آزمون‌ها را غیرفعال کرد و ۸۰٪ حالت‌های یک مجموعه‌آزمون را حذف کرد؛ از تابعی سه‌هزارخطی و ناخوانا؛ از مخزنی که در پاک‌سازی شاخه‌ها از دست رفت؛ از عاملی که پیشنهاد پاک‌کردن حافظه‌ی یک دستگاه CNC را داد؛ و از عاملی که دستور صریح را نادیده گرفت. هیچ‌کدام به هوش مصنوعی نیاز ندارد: Mars Climate Orbiter در ۱۹۹۹ از دست رفت چون یک فایل نرم‌افزار زمینی («Small Forces») ضربه‌ی پیشرانه را بر حسب lbf·s می‌داد، در حالی که نرم‌افزار ناوبری N·s انتظار داشت (گزارش فاز ۱ هیئت بررسی سانحه‌ی NASA).

مثال حل‌شده‌ی ۱: پاسخ درست با دست

در تروپوسفر ISA داریم $T = T_0 - Lh$؛ تعادل هیدرواستاتیک و قانون گاز کامل می‌دهند

$$h = \frac{T_0}{L}\left[1 - \left(\frac{p}{p_0}\right)^{RL/g_0}\right], \quad T_0 = 288.15\ \text{K},\ L = 0.0065\ \tfrac{\text{K}}{\text{m}},\ R = 287.05\ \tfrac{\text{J}}{\text{kg K}},\ g_0 = 9.80665\ \tfrac{\text{m}}{\text{s}^2}.$$

در $p = 50\,000$ Pa نما $287.05 \times 0.0065/9.80665 = 0.19026$؛ نسبت $50\,000/101\,325 = 0.49346$ و $0.49346^{0.19026} = 0.87425$؛ پس $h = 44\,331 \times 0.12575 \approx 5575$ m (با دقت کامل 5574.4 m). کاندیدای B ثابت جهانی گازها 8.314 J/(mol K) را به کار برد: نما 0.005511، حدود ۳۵ برابر کوچک‌تر، و $h \approx 172$ m. بررسی بُعدی RL/g_0 (که باید بی‌بعد باشد) این خطا را در یک خط پیدا می‌کند.

۳. مجموعه‌ای از بررسی‌ها

مقادیر مرجع از منبعی مستقل از کد می‌آیند. جدول ISA (ISO 2533:1975) در 0 m فشار 101 325 Pa و در 11 000 m فشار 22 632 Pa می‌دهد. جدول تا 1 Pa گرد شده و نزدیک 11 km داریم $|dh/dp| = RT/(pg_0) \approx 0.28$ m/Pa، پس رواداری ±1 m موجه است. B و C رد می‌شوند؛ D که ارتفاع را در فشار برابر یا بیشتر از 101 325 Pa «برای ایمنی» صفر می‌کند، قبول می‌شود.

ویژگی‌ها باید برای هر ورودی معتبر برقرار باشند: ارتفاع با فشار کم می‌شود؛ رفت‌وبرگشت فشار ← ارتفاع ← فشار همان ورودی را برمی‌گرداند؛ روز پرفشار (105 kPa) ارتفاع منفی می‌دهد. این‌ها روی ۲۰۰ نمونه‌ی تصادفی با بذر ثابت بررسی می‌شوند تا هر شکست تکرارپذیر باشد.

آزمون تفاضلی کد جدید را با پیاده‌سازی مستقل و مورد اعتماد در کل بازه‌ی کاری مقایسه می‌کند (این‌جا: تابع کتابخانه‌ی هفته‌ی ۲، 30 تا 110 kPa، ±1 m). کاندیدای A با ثابت‌های گردشده حداکثر 0.002 m انحراف دارد و همه را قبول می‌شود. کاندیدای C فرمول کتاب درسی بر حسب hPa و فوت است: با ورودی پاسکال بی‌آن‌که خطایی بدهد عدد بی‌معنی برمی‌گرداند و با مبدل (hPa → Pa و ft → m) تا 3.88 m با مرجع می‌خواند. نقص آن نبودِ قرارداد یکاست، همان الگوی Mars Climate Orbiter. نتیجه: A هر پنج بررسی را قبول می‌شود؛ B و C چهار تا را رد می‌شوند؛ D با این‌که جدول را قبول شد، چهار از پنج را رد می‌شود.

۴. راستی‌آزمایی کد: مرتبه‌ی دقت مشاهده‌شده

برای روش‌های عددی، آزمون تک‌رواداری ضعیف است. راستی‌آزمایی کد می‌پرسد آیا خطای گسسته‌سازی با نرخ وعده‌داده‌شده کم می‌شود. با خطاهای e_1, e_2 در گام‌های h_1, h_2، مرتبه‌ی مشاهده‌شده چنین است (Roy، Veluri و Luke، ۲۰۱۲، معادله‌ی ۴):

$$\hat{p} = \frac{\ln\left(e_1/e_2\right)}{\ln\left(h_1/h_2\right)}.$$

مثال حل‌شده‌ی ۲: RK4 با اشتباه تایپی یک‌نویسه‌ای

یک گام RK4 کلاسیک برای $\dot{x} = -x$، $x_0 = 1$ و $h = 0.1$: $k_1 = -1$، $k_2 = -0.95$، $k_3 = -0.9525$، $k_4 = -0.90475$؛ پس $x_1 = 1 + \frac{0.1}{6}(-1 - 1.9 - 1.905 - 0.90475) = 0.9048375$ و خطا 8.2×10^{-8}. حال نوسانگر پیچ $\ddot{\theta} + 2\zeta\omega_n\dot{\theta} + \omega_n^2\theta = 0$ ($\omega_n = 3$، $\zeta = 0.5$، $\theta_0 = 0.1$ rad، rad/s) را تا $T = 2$ s با RK4 درست و با نسخه‌ای که k_3 را از k_1 به جای k_2 می‌سازد انتگرال بگیرید. در $h = 0.05$ هر دو آزمون رواداری 10^{-5} را قبول می‌شوند (خطاها 1.21×10^{-7} و 6.93×10^{-6}). مرتبه‌های مشاهده‌شده حقیقت را می‌گویند:

h (s)	0.1	0.05	0.025	0.0125	مرتبه‌ی مشاهده‌شده
اویلر	7.25e-3	2.78e-3	1.23e-3	5.80e-4	1.38، 1.18، 1.09
RK4 با اشتباه	4.48e-5	6.93e-6	1.19e-6	2.29e-7	2.69، 2.55، 2.38
RK4	1.87e-6	1.21e-7	7.65e-9	4.80e-10	3.95، 3.99، 4.00

با دست از سطر اشتباه: $\ln(6.929/1.186)/\ln 2 = 2.547$ ، نه ۴. وقتی جواب دقیق وجود ندارد، روش جواب‌های ساختگی یکی می‌سازد.

۵. آزمودن آزمون‌ها: آزمون جهش

آزمون‌هایی که روی کد غلط هم قبول می‌شوند چیزی را ثابت نمی‌کنند. آزمون جهش نقص‌های معلوم (جهش‌یافته‌ها) را در منبع مورد اعتماد می‌کارد و می‌شمارد مجموعه‌آزمون چندتا را می‌گیرد (می‌کشد). روی شش جهش‌یافته‌ی تابع ISA (R جهانی، مرجع hPa، محدودکننده‌ی سطح دریا، نمای وارونه، خطای علامت، فقط اسکالر)، چهار مجموعه که همه روی کد درست قبول می‌شوند این امتیازها را می‌گیرند: ضعیف («اجرا و m 0 در سطح دریا») ۱/۶؛ معمول (+ یک مقدار دستی) ۴/۶؛ قوی (+ جدول، زیر سطح دریا، آرایه، یکنوایی) ۶/۶؛ و مجموعه‌ی قوی که اظهارهای ردشده‌ی D از آن حذف شده، یعنی همان حرکت «آزمون‌ها را قبول کن» در داستان هشداردهنده، به ۴/۶ برمی‌گردد. پایش امتیاز، حذف بی‌صدا را به افتی آشکار تبدیل می‌کند.

۶. بررسی‌های ایستا و محیط

پیش از اجرای هر چیز آنچه خواسته‌اید را بشمارید («بچه‌هایتان را بشمارید» از Kim و Yegge): ممکن است پاسخ تابعی را جا انداخته یا تابع ناخواسته‌ای افزوده باشد. سپس importهایی را که پیدا نمی‌شوند فهرست کنید. Spracklen و همکاران (USENIX Security 2025) با ۱۶ مدل ۵۷۶ هزار نمونه ساختند: به‌طور میانگین دست‌کم 5.2٪ بسته‌های پیشنهادی مدل‌های تجاری و 21.7٪ مدل‌های متن‌باز وجود نداشتند، با ۲۰۵ ۴۷۴ نام ساختگی یکتا که مهاجم می‌تواند ثبتشان کند. در پایان محیط را قفل کنید: در محیط درس (NumPy 1.26.4) هست و `np.trapz` نیست؛ در NumPy 2.5.3 برعکس است. قاعده‌های «Power of 10» از Holzmann برای کد ایمنی‌بحرانی به‌خوبی منتقل می‌شوند: دست‌کم دو اظهار در هر تابع (قاعده‌ی ۵) و صفر هشدار با تحلیل ایستای روزانه (قاعده‌ی ۱۰).

۷. شواهد چه می‌گویند و حدودشان

در یک کارآزمایی تصادفی (Peng و همکاران، ۲۰۲۳) ۹۵ فریلنسر یک سرور HTTP را با JavaScript و GitHub Copilot 55.8٪ سریع‌تر نوشتند (بازه‌ی اطمینان ۹۵٪: ۲۱ تا ۸۹٪). در کارآزمایی دیگری (METR، ۲۰۲۵) ۱۶ توسعه‌دهنده‌ی باتجربه روی ۲۴۶ مسئله‌ی واقعی در مخزن‌های بزرگ خودشان با ابزارهای اوایل ۲۰۲۵ **۱۹٪ زمان بیشتری** صرف کردند (بازه‌ی +۲ تا +۳۹٪)، هرچند ۲۴٪ تسریع پیش‌بینی کرده بودند و پس از آن ۲۰٪ تسریع باور داشتند. پیگیری METR ۲۰۲۶ مقادیر -۱۸٪ (بازه‌ی -۳۸ تا +۹٪) و -۴٪ (بازه‌ی -۱۵ تا +۹٪) را اندازه گرفت و آن را شواهد بسیار ضعیف نامید. پیمایش DORA 2024 برآورد کرد که با افزایش پذیرش هوش مصنوعی توان تحویل 1.5٪ و پایداری 7.2٪ کم شد. در امنیت، حدود ۴۰٪ از ۱۶۸۹ برنامه‌ی Copilot در

۸۹ سناریوی پرخطر آسیب‌پذیر بودند (Pearce و همکاران) و کاربران با دستیار کد ناامن‌تری نوشتند و آن را امن‌تر می‌پنداشتند (Perry و همکاران). یک آزمون فروشنده (Veracode، ۲۰۲۵) در ۴۵٪ حالت‌ها نقص گزارش کرد؛ داوری همتا ذکر نشده است. نتیجه: سود بزرگ روی کارهای کوچک و خوش‌تعریف واقعی است؛ در کد پیچیده و آشنا ممکن است از بین برود، و احساس سرعت شاهد نیست. چند آمار رایج (مثلاً «۶۳٪ کاربران غیرتوسعه‌دهنده‌اند») منبع قابل‌ردیابی ندارند و این‌جا به کار نرفته‌اند.

مثال حل‌شده‌ی ۳: لاگ آزمون ایستای موتور (تکلیف تمرینی)

یک لاگ مصنوعی لودسل (نیم‌سینوسی، 120 N، 1.6 s؛ ضربه‌ی دقیق $2Ft_b/\pi = 122.23$ N·s) ۴۹۸ نمونه با لرزش زمانی و سه بسته‌ی گمشده دارد. صفرکردن نویز منفی و قاعده‌ی ذوزنقه روی زمان‌های واقعی $I = 122.30$ N·s و با 65 g پیشران $I_{sp} = I/(mg_0) = 191.86$ s می‌دهد. میان‌بُر رایج `dt = t[1] - t[0]` مقدار 97.85 N·s (۲۰٪ کمتر) می‌دهد. بررسی همگرایی روی شبکه‌ی یکنواخت این خطا را نمی‌بیند؛ یک حالت مرجع روی شبکه‌ی غیریکنواخت می‌بیند. هر بررسی بخشی از نقص‌ها را می‌بیند و به همین دلیل آن‌ها را ترکیب می‌کنیم.

۸. روش کار

قطعه‌های کوچک و خوش‌تعریف با معیار قابل‌بررسی واگذار کنید؛ وقتی کار نو یا ایمنی‌مرتبط است بیشتر نظارت کنید؛ ویرایش آزمون، داده و سخت‌افزار را ممنوع کنید؛ پس از هر گام بررسی و پیش از هر تغییر عامل commit کنید؛ و یک فایل پروژه با یکاها، قراردادها و نسخه‌های قفل‌شده نگه دارید (برگرفته از Kim و Yegge، فصل ۴). درخواست را با یکا، بازه، محیط و دو یا سه مقدار مرجع بنویسید و پیش از کد، فرض‌ها و حالت‌های مرزی را بخواهید. داده‌ای را که برای سرویس بیرونی مجاز نیست وارد نکنید و پیش از بررسی بسته و ناشرش چیزی نصب نکنید. امضای نتیجه با شماست.

جمع‌بندی. اکنون می‌توانیم وایب‌کدینگ را از مهندسی با کمک هوش مصنوعی جدا کنیم، کد هوش مصنوعی را با مقادیر مرجع، ویژگی‌ها و آزمون تفاضلی راستی‌آزمایی کنیم، مرتبه‌ی مشاهده‌شده‌ی کد عددی را بسنجیم، مجموعه‌آزمون را با امتیاز جهش داوری کنیم، بررسی ایستا انجام دهیم و مطالعات هوش مصنوعی را نقادانه بخوانیم.

منابع

Kim, G., Yegge, S. *Vibe Coding*. IT Revolution, 2025 · Willison, S. “Not all AI-assisted programming is vibe coding”, simonwillison.net, 19 Mar 2025 · Peng, S. et al. arXiv:2302.06590 · METR, arXiv:2507.09089 and metr.org blog, 24 Feb 2026 · Google Cloud, DORA 2024 report blog · Pearce, H. et al. arXiv:2108.09293 · Perry, N. et al. ACM CCS 2023, doi:10.1145/3576915.3623157 · Spracklen, J. et al. USENIX Security 2025, arXiv:2406.10279 · Veracode press release, 30 Jul 2025 · NASA MCO Mishap Investigation Board, Phase I Report, 10 Nov 1999 · Holzmann, G. J. “The Power of 10”, NASA/JPL · Veluri, Roy, Luke, *Computers & Fluids*, 2012 · DeMillo, Lipton, Sayward, *IEEE Computer* 11(4), 1978 · ISO 2533:1975 Standard Atmosphere.